Pop Alessandro Cristian 311CC

Documentatie Partea I

CONSTRUIREA SI EXPLORAREA UNUI DATASET TABELAR

- In prima parte am ales dataset-ul. Am gasit un dataset cu toti jucatorii de pe jocul FIFA21 si toate atributiile lor. Am salvat datasetul, am extras doar anumite coloane (la inceput erau 77 de coloane iar eu am ectras 16 care mi s-au parut cele mai relevante) si am inceput sa fac cleaning. Am generat o noua coloana numita Body Mass Index care este rezultatul a unor operatii cu alte coloane din dataset. Dupa am simulat 5% valori random de Nan pe coloana PAC pentru a face cleaning atat pe setul de train cat si pe cel de test.

CERINTE DETALIATE
1. Setul de date ales este destinat unei probleme de regresie. Modelul v-a trebui sa afle valoarea unui jucator bazandu-se pe atributele sale, cum ar fi OverallRating, Potential, viteza, varsta etc.

2. Setul de date principal a fost impartit in doua subset-uri, unul pentru antrenare iar celelalt pentru testare.

3. Dataset-ul are 16 coloane si 3 tipuri de date : numere intregi, numere reale si siruri de caractere.

4. Dataset-urile au fost salvate in format csv prin comanda to_csv().

6. a. Analiza valorilor lipsa - pentru inceput am creeat un tabel cu numarul de valori null de pe ficare coloana si procentul, atat pentru datasetul de train cat si pentru cel de test. Dupa ce am observat coloana unde erau probleme, am adaugat la toate valorile null, media de pe coloana respectiva.

	Numar train	Procent train	Numar test	Procent test
Name	0	0.000000	0	0.000000
Nationality	0	0.000000	0	0.000000
↓OVA	0	0.000000	0	0.000000
Age	0	0.000000	0	0.000000
POT	0	0.000000	0	0.000000
Positions	0	0.000000	0	0.000000
Height	0	0.000000	0	0.000000
Weight	0	0.000000	0	0.000000
Value	0	0.000000	0	0.000000
PAC	759	4.999012	182	4.794521
SHO	0	0.000000	0	0.000000
PAS	0	0.000000	0	0.000000
DRI	0	0.000000	0	0.000000
DEF	0	0.000000	0	0.000000
PHY	0	0.000000	0	0.000000
BMI	0	0.000000	0	0.000000

b.Statistici descriptibe - pentru cele 2 subset-uri am afisat cu functia describe(), tabele care ne ofera informatii legate de minim, maxim, medie. De exemplu varsta medie in dataset este 25 de ani iar overall-ul este 65. Pentru variabilele categorice, cum ar fi Name, Nationality si Positions, tabelul ne ofera informatii legate de unicitate, frecventa, etc.

Statistici Descriptive
Subset Train

	↓OVA	Age	POT	Height	Weight	Value	PAC	SHO	PAS	DRI	DEF	PHY	BMI
count	15183.000000	15183.000000	15183.000000	15183.000000	15183.000000	1.518300e+04	15183.000000	15183.00000	15183.000000	15183.000000	15183.000000	15183.000000	15183.000000
mean	65.707831	25.162155	71.176118	1.811886	75.006981	2.873556e+06	67.493899	53.50932	57.651913	62.886781	49.775143	64.377066	22.819984
std	6.998174	4.715603	6.126316	0.068356	7.061659	7.693424e+06	10.312575	13.81014	10.080278	9.903029	16.489120	9.624748	1.364843
min	47.000000	16.000000	47.000000	1.550000	50.000000	0.000000e+00	25.000000	17.00000	25.000000	25.000000	12.000000	28.000000	17.358919
25%	61.000000	21.000000	67.000000	1.760000	70.000000	4.750000e+05	62.000000	44.00000	51.000000	57.000000	35.000000	58.000000	21.913806
50%	66.000000	25.000000	71.000000	1.810000	75.000000	9.500000e+05	67.493899	56.00000	58.000000	64.000000	53.000000	65.000000	22.837370
75%	70.000000	28.000000	75.000000	1.860000	80.000000	2.000000e+06	74.000000	64.00000	64.000000	69.000000	63.000000	71.000000	23.671254
max	92.000000	53.000000	95.000000	2.030000	110.000000	1.855000e+08	96.000000	93.00000	93.000000	94.000000	91.000000	91.000000	34.717839

	Name	Nationality	Positions
count	15183	15183	15183
unique	14461	157	593
top	J. Rodríguez	England	CB
freq	11	1370	1937

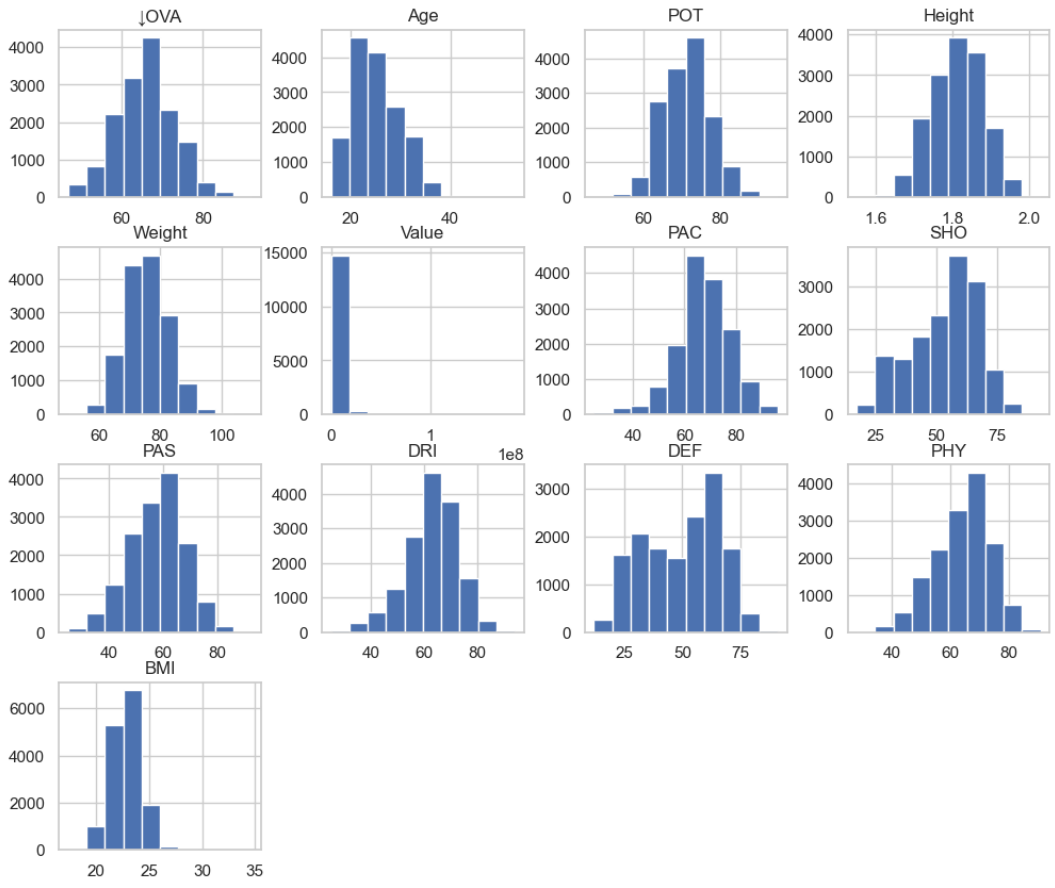
Subset Test

	↓OVA	Age	POT	Height	Weight	Value	PAC	SHO	PAS	DRI	DEF	PHY	BMI
count	3796.000000	3796.000000	3796.000000	3796.000000	3796.000000	3.796000e+03	3796.000000	3796.000000	3796.000000	3796.000000	3796.000000	3796.000000	3796.000000
mean	65.761855	25.321918	70.977608	1.812466	75.067176	2.831095e+06	67.363248	53.247893	57.797418	62.827977	50.230506	64.336407	22.821907
std	6.851804	4.688579	6.065890	0.068584	7.121603	7.652906e+06	10.844384	13.896206	10.088661	10.025536	16.255351	9.511070	1.357596
min	47.000000	16.000000	48.000000	1.590000	53.000000	0.000000e+00	28.000000	16.000000	25.000000	27.000000	15.000000	31.000000	17.961266
25%	61.750000	22.000000	67.000000	1.760000	70.000000	4.750000e+05	62.000000	43.000000	51.000000	57.000000	35.000000	58.000000	21.913806
50%	66.000000	25.000000	71.000000	1.810000	75.000000	9.500000e+05	67.493899	56.000000	59.000000	64.000000	54.000000	65.500000	22.839506
75%	70.000000	29.000000	75.000000	1.860000	80.000000	2.000000e+06	74.000000	64.000000	65.000000	69.000000	63.000000	71.000000	23.666910
max	93.000000	43.000000	93.000000	2.060000	107.000000	1.290000e+08	96.000000	92.000000	93.000000	95.000000	87.000000	88.000000	29.761905

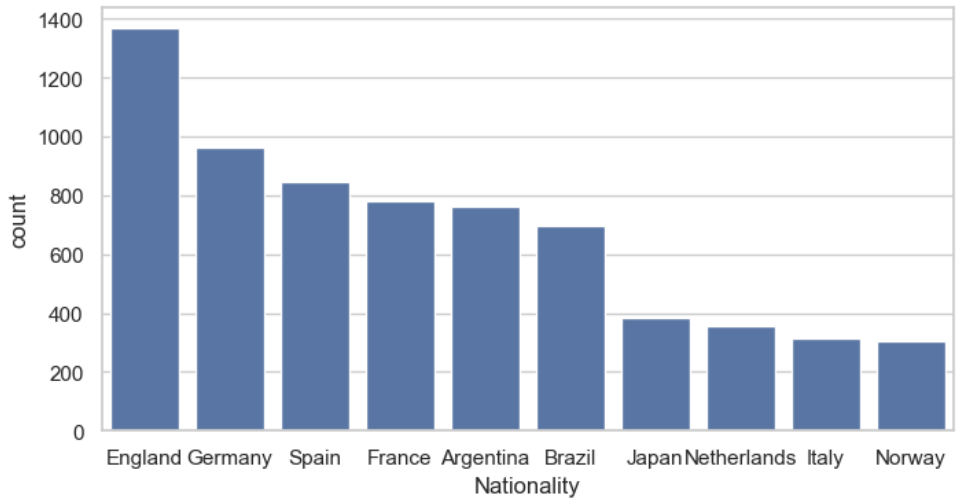
	Name	Nationality	Positions
count	3796	3796	3796
unique	3743	129	345
top	J. García	England	CB
freq	4	335	504

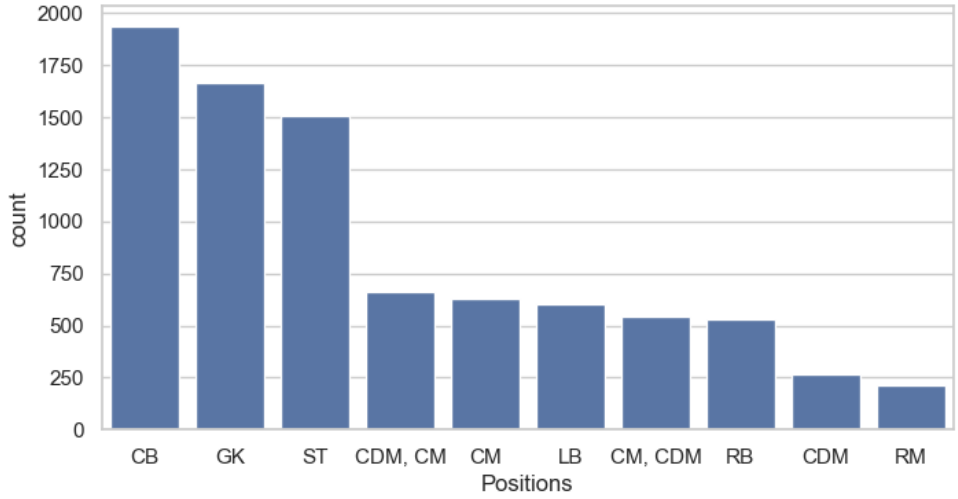
c. Analiza distributiei variabilelor - Am generat histograme pentru variabilele numerice si countplot-uri pentru cele categorice.

- Din histograme observam ca majoritatea variabilelor, de exemplu Age, OVA si PAC, au o distributie aproximativ normala. In schimb Value are o distributie extrem de asimetrica, ceea ce inseamna ca majoritatea jucatorilor au o valoarea mica, in timp ce un numar de jucatori au valori foarte mari.

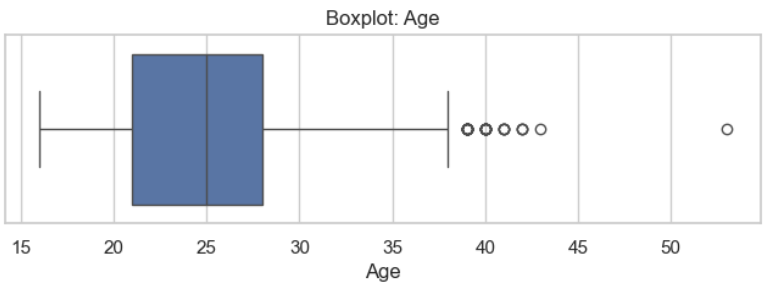


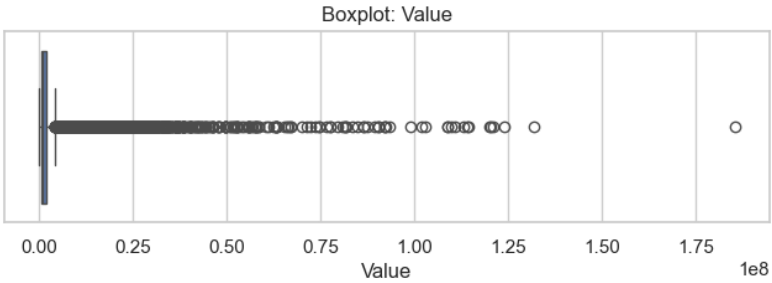
- Din countplot-uri se observa ca Anglia are cei mai multi jucatori,iar pozitia CB este cea mai frecventa.

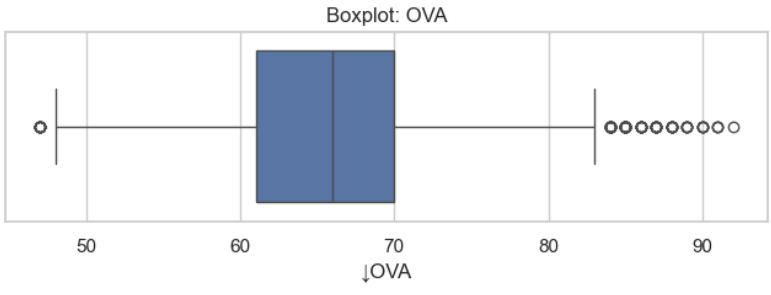




d. Detectarea outlierilor - am folosit boxplot-uri pentru a detecte outlieri la 3 categorii : Age, Value si Ova. La categoria de varsta, jucatorii care ies in evidenta sunt cei batrani, la cea de value, se observa jucatorii scumpi cu preturi de peste 50 de milioane de euro iar la cea de overall se observa jucatorii cu un OVA de peste 85.



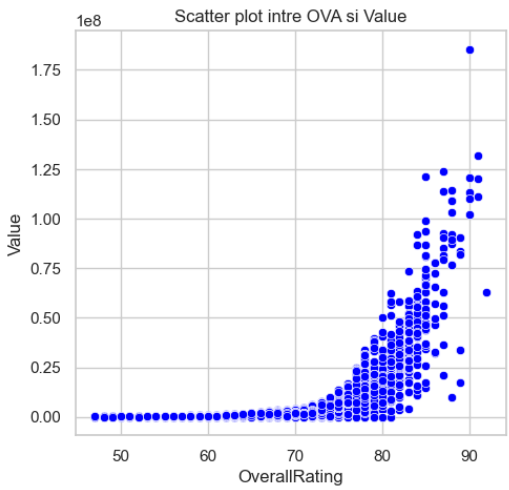


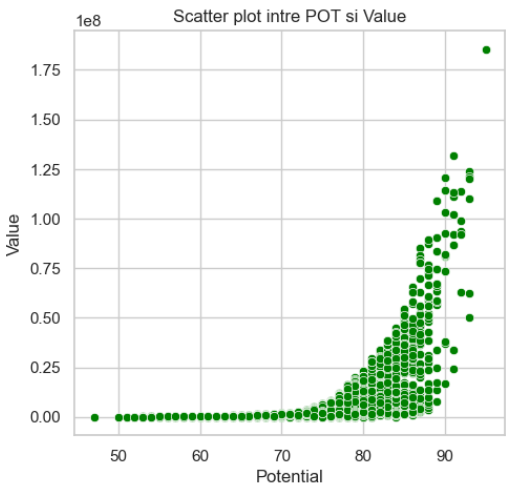


e. Analiza corelatiilor - am extras exclusiv valorile numerice din dataset si am creeat un heapmap cu functia .heatmap(). Analizand heatmap-ul, se observ corelatii puternice intre value si OVA sau POT. Totodata, se observa o corelatie negativa intre Age si Pac, ceea ce indica faptul ca pe masura ce un jucator imbatraneste, viteza lui scade. Pe de alta parte, se observa faptul ca driblingul(DRI) si passingul(PAS) sunt in corelatie aproape 1 (0.83), indicand faptul ca daca un jucator este bun la una dintre acestea, v-a fi bun si la cealalta.



f.Analiza relatiilor cu variabila tinta - am generat scatterplot-uri pentru a observa relatia dintre Value si cele mai corelate caracteristici: OVA, POT si Age. Din scatterplot-urile cu OVA si POT se observa ca pe masura ce ratingul sau potential creste ,si valoarea acestuia creste in mod semnificativ (este o relatie exponentiala). La scatterplot-ul cu varsta, se observa ca cei mai scumpi jucatori sunt in prime adica au intre 23 si 29 de ani. Cei tineri sau cei batrani sunt semnificativ mai ieftini.



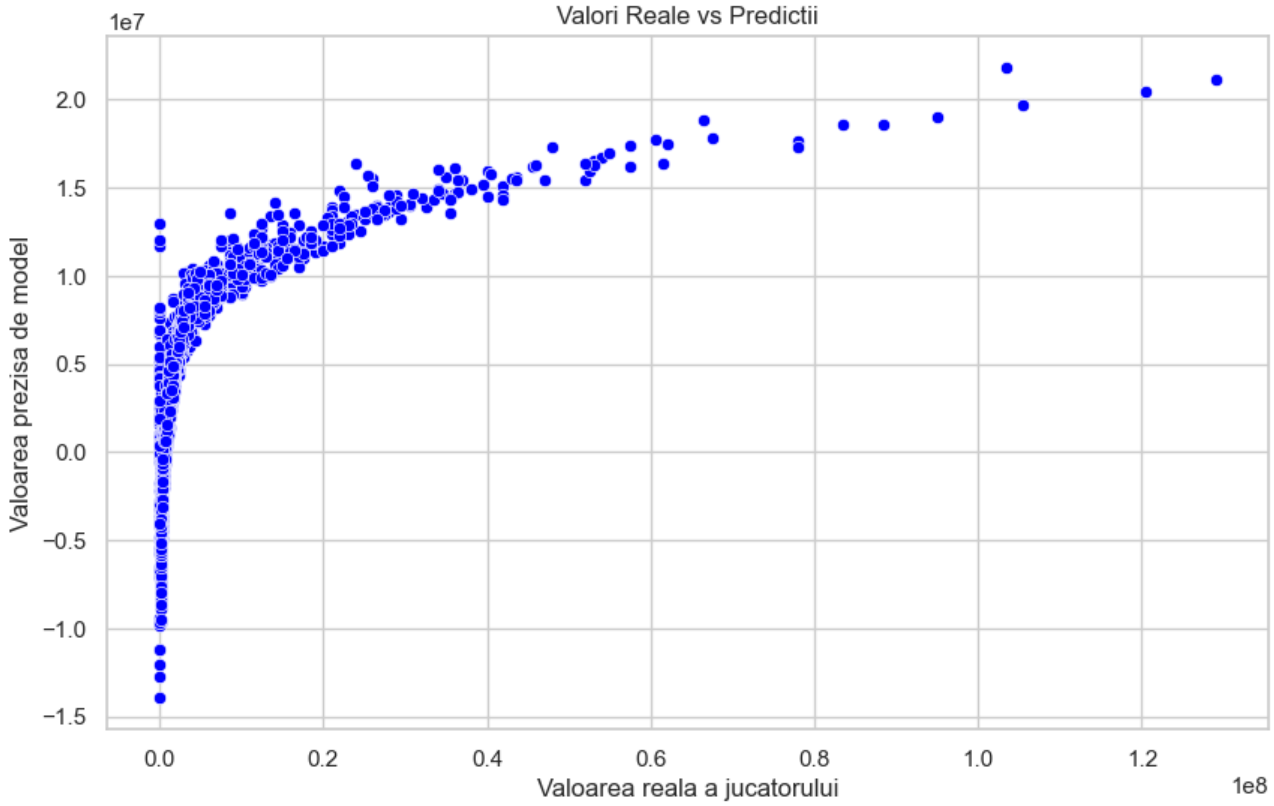




7. Antrenarea si evaluarea unui model de baza
- Am antrenat un model de regresie liniara utilizand exclusiv valorile numerice.
- Am raportat si interpretat rezultatele folosind mean absolut error, mean squared error si r2 score:

Mean Absolute Error: 3074416.59 euro
Root Mean Squared Error: 6052494.44 euro
R^2: 0.37

- Apoi am implementat un scatterplot pentru a compara valorile reale vs valorile prezise. Analiza graficului explica aceste erori: modelul genereaza sume negative pentru jucatori ieftini si se opreste la aproximativ 20 de milioane de euro,subestimand valoarea jucatorilor scumpi care poate trece de 100 de milioane de euro.



- Concluzie : regresia liniara este incapabila sa observe cresterea exponentiala preturilor jucatorilor. Totodata, valoarea jucatorilor este extrasa dintr-un dataset cu valori dintr-un joc video, ceea ce explica faptul ca jucatorii cu rating mare au o valoarea colosala, pe cand cei cu rating mic sunt mult mai ieftini.